

BÁO CÁO KỸ THUẬT

DATA EXPLORERS 2026 – Vòng 2

From Data to Decision by MEXC Ventures

NHÓM DATASYNC

Nguyễn Đăng Hoàng Ân	Nhóm trưởng
Lê Thiên Đức	Thành viên
Tạ Ngọc Bảo Ngân	Thành viên
Nguyễn Trang Nhật Mai	Thành viên
Nguyễn Quỳnh Trâm	Thành viên

Email liên hệ: datasync5ueh@gmail.com

Ngày hoàn thành: 03/05/2026

MỤC LỤC

1. Tổng quan dự án và bối cảnh
2. Hạng mục A: Xử lý đơn hàng tự động
 - 2.1 Kiến trúc pipeline
 - 2.2 Thư viện và công nghệ sử dụng
 - 2.3 Xử lý file .eml – parse_email.py
 - 2.4 Trích xuất PDF – parse_pdf.py
 - 2.5 Kiểm tra hợp lệ – validate.py
 - 2.6 Ghi database – db_writer.py
 - 2.7 Điều phối pipeline – main.py
 - 2.8 Xử lý trường hợp đặc biệt
3. Kết quả đạt được
4. Schema database
5. Hướng dẫn cài đặt và chạy
6. Kết luận và kế hoạch tiếp theo

1. TỔNG QUAN DỰ ÁN VÀ BỐI CẢNH

Công ty Cổ phần Xe đạp Thống Nhất là doanh nghiệp sản xuất và phân phối xe đạp với hơn 200 SKU, 5 nhóm sản phẩm chính, vận hành theo mô hình B2B với hơn 700 đại lý trên toàn quốc. Hiện tại, đại lý đặt hàng qua email, điện thoại hoặc Zalo; nhân viên phải nhập thủ công vào hệ thống ERP, dẫn đến tốn nhiều thời gian và dễ xảy ra sai sót.

Mục tiêu Vòng 2 – DATA EXPLORERS 2026:

- Tự động hóa xử lý 1.132 đơn hàng email tháng 3/2026.
- Xây dựng dashboard phân tích kinh doanh đa chiều (dữ liệu 2025 – T3/2026).
- Dự báo nhu cầu Q2/2026 theo sản phẩm, màu sắc và hoạt động đại lý.
- Trình bày và bảo vệ kết quả trước hội đồng giám khảo.

Phân bổ điểm

Hạng mục	Nội dung	Điểm
A	Vận hành: Xử lý đơn hàng tự động	25
B	Phân tích: Dashboard & Insights	30
C	Dự báo nhu cầu & Chiến lược	30
D	Trình bày & Bảo vệ	15
Tổng		100

2. HẠNG MỤC A: XỬ LÝ ĐƠN HÀNG TỰ ĐỘNG (25 ĐIỂM)

Nhóm chọn Phương án A (Email + PDF, file .eml) để đạt mức tối đa 25/25 điểm. Pipeline được viết hoàn toàn bằng Python, tự động xử lý từ đầu đến cuối mà không cần can thiệp thủ công sau khi khởi động.

2.1 Kiến trúc Pipeline

```
1.132 file .eml
|
v
parse_email.py  <-- Phân tích email: From, Subject, Date, Message-ID, file PDF đính kèm
|
v
parse_pdf.py    <-- Trích xuất PDF: số đơn, ngày, MST, tên khách hàng, bảng sản phẩm
|
v
validate.py     <-- Kiểm tra hợp lệ: trùng lặp, ngày tháng, mã hàng, số lượng, thành tiền
|
v
db_writer.py    <-- Ghi vào PostgreSQL: email_log -> sales_order -> order_line -> fact_sales
```

Pipeline thiết kế theo nguyên tắc idempotent: có thể chạy lại nhiều lần mà không gây trùng lặp dữ liệu. Cơ chế: kiểm tra message_id (chỉ xử lý nếu chưa có trong email_log với trạng thái SUCCESS) và so_number (kiểm tra trong sales_order trước khi INSERT).

2.2 Thư viện và Công nghệ sử dụng

Thư viện / Công nghệ	Phiên bản	Mục đích
Python	3.13	Ngôn ngữ lập trình chính
pdfplumber	>=0.10.0	Trích xuất bảng biểu từ PDF
psycopg2-binary	>=2.9.0	Kết nối và ghi dữ liệu vào PostgreSQL
email (stdlib)	built-in	Phân tích cấu trúc MIME của file .eml
PostgreSQL	14+	Cơ sở dữ liệu quan hệ lưu trữ đơn hàng

2. HẠNG MỤC A (tiếp theo)

2.3 Xử lý file .eml – parse_email.py

Mỗi file .eml có cấu trúc MIME nhiều tầng: header có thể mã hóa Base64 hoặc Quoted-Printable, file PDF đính kèm là payload nhị phân. Hàm parse_email() xử lý:

- Giải mã header: dùng decode_header() để xử lý cả UTF-8 và ASCII.
- Trích message_id, from_address, received_at (parsedate_to_datetime).
- Trích số đơn hàng từ Subject bằng regex: BH26[. _](\d+).
- Tìm file PDF đính kèm trong cây MIME (Content-Type: application/pdf).
- Giải mã base64 lấy pdf_bytes trả về để bước tiếp theo xử lý.
- Trích MST từ body email bằng regex: MST[:\s]*([0-9]{9,10}).

2.4 Trích xuất PDF – parse_pdf.py

Dùng pdfplumber để trích xuất bảng biểu từ PDF. Mỗi đơn hàng có thể trải dài nhiều trang (thường 2–5 trang với đơn hàng có nhiều sản phẩm). Cách xử lý:

- Trang đầu, bảng đầu tiên = bảng header đơn hàng: số đơn, ngày đặt, MST, tên đại lý.
- Các bảng còn lại (tất cả trang) = bảng sản phẩm: STT | Mã hàng | Tên SP | ĐVT | SL | Đơn giá | Thành tiền.
- Lọc dòng tiêu đề bảng (dòng STT) và dòng tổng cộng (STT trống, không có mã hàng).
- Hàm _is_product_code() nhận diện mã hàng: số thuần 10–16 ký tự HOẶC dạng TP0099.0000570.
- Hàm _parse_amount() xử lý số VND: '1.898.148' → 1898148.0 (dấu chấm là phân ngàn).
- Xử lý trường hợp PDF có encoding tiếng Việt bị garble – các trường số liệu (mã hàng, giá) vẫn là ASCII.

2.5 Kiểm tra hợp lệ – validate.py

Pipeline kiểm tra 5 nhóm điều kiện trước khi ghi dữ liệu vào database:

Nhóm kiểm tra	Nội dung	Xử lý khi lỗi
1. Số đơn hàng	Phải có so_number, không được trùng với DB	Fatal – bỏ qua đơn
2. Ngày đặt hàng	Phải thuộc tháng 3/2026	Ghi lỗi, bỏ qua
3. Khách hàng	Phải có MST trong PDF hoặc email body	Ghi lỗi
4. Mã sản phẩm	Phải tồn tại trong bảng product của DB	Ghi lỗi tổng hợp
5. Số lượng & giá	qty > 0, đơn giá >= 0, thành tiền khớp tính toán	Ghi lỗi từng dòng

Kiểm tra thành tiền dùng dual-tolerance để xử lý cả đơn hàng số lượng lớn (đơn giá có phần lẻ thập phân) và đơn hàng thông thường:

```
expected = qty * unit_price
abs_diff = abs(expected - line_total)
rel_diff = abs_diff / line_total      # sai lệch tương đối

# Chỉ báo lỗi khi CẢ HAI điều kiện vượt ngưỡng:
if abs_diff > 50 and rel_diff > 0.0001: # 50 VND tuyệt đối VÀ 0,01% tương đối
    errors.append(...)
```

2.6 Ghi database – db_writer.py

Toàn bộ việc ghi dữ liệu thực hiện trong một transaction để đảm bảo tính nhất quán:

- Tra cứu customer_code từ tax_code (MST): khớp chính xác, rồi khớp sau khi LTRIM('0').
- INSERT email_log: ghi trạng thái ngay từ đầu (PROCESSING).
- INSERT sales_order: số đơn, ngày, khách hàng – trigger tự động cập nhật tổng tiền/số lượng.
- INSERT order_line (execute_batch): chèn nhanh toàn bộ dòng sản phẩm trong một lần gọi.
- UPDATE email_log: đổi trạng thái thành SUCCESS hoặc ERROR kèm chi tiết lỗi.
- populate_fact_sales(): INSERT...SELECT kết nối 7 bảng, dùng NOT EXISTS để tránh trùng.

2.7 Điều phối Pipeline – main.py

main.py kết nối các module lại với nhau, hiển thị thanh tiến trình, ghi log chi tiết và xuất file summary.json sau khi chạy xong:

```
for eml_path in eml_files:
    eml = parse_eml(eml_path)           # Bước 1: phân tích email
    pdf = parse_pdf(eml['pdf_bytes'])   # Bước 2: trích xuất PDF
    errs = validate_order(eml, pdf, ...) # Bước 3: kiểm tra hợp lệ
    if errs:
        log_error(errs); continue
    customer = lookup_customer(conn, mst) # Bước 4: tra cứu khách hàng
    insert_order(conn, eml, pdf, customer) # Bước 5: ghi database
    existing_so.add(so_number)           # Cập nhật cache tránh trùng
```

2.8 Xử lý Trường hợp Đặc biệt

Trong quá trình chạy, phát hiện và xử lý các vấn đề phát sinh sau:

Vấn đề	Số lượng	Giải pháp
Khách hàng mới (MST chưa có trong DB)	92 MST	fix_missing_data.py: tự động đăng ký KH mới
Mã sản phẩm mới chưa có trong DB	~30 mã	fix_all_remaining.py: tự động thêm sản phẩm mới
Mã SP dạng TP0099.0000570 (có dấu chấm)	2 đơn	Cập nhật regex _is_product_code()
Sai lệch thành tiền > 50 VND (đơn lớn)	1 đơn	Thêm kiểm tra sai lệch tương đối 0,01%
Email trùng (đã xử lý lần trước)	Nhiều	Bỏ qua qua cache message_id (chỉ SUCCESS)

3. KẾT QUẢ ĐẠT ĐƯỢC

Sau khi chạy pipeline và xử lý các trường hợp đặc biệt, toàn bộ 1.132 đơn hàng đã được ghi thành công:

Bảng	Số dòng T3/2026	Mô tả
email_log	1.132 (100% SUCCESS)	Nhật ký trạng thái xử lý từng email
sales_order	1.132 đơn hàng	Đơn hàng BH26.0935 đến BH26.2066
order_line	8.721 dòng	Chi tiết sản phẩm trong từng đơn
fact_sales	8.721 dòng	Dữ liệu phân tích doanh thu đa chiều

Thông kê doanh thu tháng 3/2026

Chỉ số	Giá trị
Tổng số đơn hàng	1.132 đơn
Tổng số lượng xe	25.489 chiếc
Tổng doanh thu	40.691.947.133 VND (~40,7 tỷ VND)
Doanh thu bình quân mỗi đơn	~35,9 triệu VND
Số dòng sản phẩm trung bình mỗi đơn	7,7 dòng
Tỷ lệ xử lý thành công	100% (1.132/1.132)

Toàn bộ dữ liệu tháng 3/2026 đã sẵn sàng trong database, cùng với lịch sử 2025–T2/2026 (17.031 dòng fact_sales), tạo nền tảng cho phân tích và dự báo ở các hạng mục tiếp theo.

4. SCHEMA DATABASE

Cơ sở dữ liệu: tnbike_db | Schema: tnbike | PostgreSQL 14

Gồm 9 bảng chính + 4 views + 1 trigger tự động cập nhật tổng tiền đơn hàng:

Bảng	Số dòng (sau pipeline)	Mô tả
product_group	5	Nhóm sản phẩm (Trẻ Em, Địa Hình, Phổ Thông,...)
product_line	~75	Dòng sản phẩm trong từng nhóm
product	247+	SKU sản phẩm (mã hàng, tên, đơn vị tính)
product_price	247+	Lịch sử giá bán theo thời gian
province	63	Tỉnh/thành phố và vùng miền
customer	700+	Đại lý (mã KH, tên, MST, tỉnh, tier)
sales_order	1.132 T3/2026	Đơn hàng (số đơn, ngày, KH, tổng tiền)
order_line	8.721 T3/2026	Dòng sản phẩm (mã, số lượng, đơn giá, thành tiền)
fact_sales	8.721 T3/2026	Bảng phân tích đầy đủ chiều dữ liệu
email_log	1.132	Nhật ký xử lý email (bảng thêm bởi pipeline)

Trigger trg_order_line_after_insert: sau mỗi INSERT vào order_line, tự động cập nhật total_amount, total_quantity và line_count trong sales_order.

5. HƯỚNG DẪN CÀI ĐẶT VÀ CHẠY

Yêu cầu hệ thống

- Python 3.11+ (khuyến nghị 3.13)
- PostgreSQL 14+ (port 5432)
- RAM tối thiểu 4 GB
- Thư mục chứa 1.132 file .eml của tháng 3/2026

Các bước cài đặt

Bước 1: Sao chép mã nguồn

```
git clone https://github.com/NguyenAn1-data/dataexplorers2026-v2.git
cd dataexplorers2026-v2
```

Bước 2: Cài thư viện Python

```
pip install -r pipeline/requirements.txt
```

Bước 3: Cấu hình database

```
copy pipeline\config.example.py pipeline\config.py
# Mở config.py, điền mật khẩu PostgreSQL và đường dẫn thư mục email
```

Bước 4: Khởi tạo database

```
cd pipeline
python setup_db.py
# Tạo tnbike_db, chạy 01_create_tables.sql + 02_import_data.sql
```

Bước 5: Chạy pipeline

```
python main.py
# Xử lý 1.132 file .eml, ghi vào database
# Xem kết quả tổng hợp: logs/summary.json
```

Kiểm tra kết quả trong pgAdmin

```
-- Kiểm tra trạng thái xử lý email
SELECT processing_status, COUNT(*)
FROM tnbike.email_log
GROUP BY processing_status;
-- Kết quả mong đợi: SUCCESS = 1132

-- Kiểm tra doanh thu tháng 3/2026
SELECT COUNT(*) AS so_don, SUM(total_amount) AS doanh_thu
FROM tnbike.sales_order
WHERE fiscal_year = 2026 AND fiscal_month = 3;
-- Kết quả mong đợi: 1132 đơn, ~40,7 tỷ VND
```

6. KẾT LUẬN VÀ KẾ HOẠCH TIẾP THEO

Kết quả Hạng mục A

Nhóm DataSync đã xây dựng thành công pipeline xử lý đơn hàng tự động đạt 100% hiệu quả (1.132/1.132 đơn hàng). Lựa chọn Phương án A (Email + PDF) thay vì chỉ đọc PDF giúp tối đa hóa điểm số (25 điểm thay vì 20 điểm). Pipeline có khả năng:

- Xử lý cấu trúc MIME phức tạp của email (base64, quoted-printable, đa tầng).
- Trích xuất chính xác dữ liệu từ PDF nhiều trang bằng pdfplumber.
- Kiểm tra hợp lệ toàn diện với dual-tolerance cho tính toán tài chính.
- Tự động đăng ký khách hàng và sản phẩm mới phát hiện trong email.
- Chạy idempotent: an toàn khi khởi động lại, không gây dữ liệu trùng lặp.
- Ghi dữ liệu đúng schema: email_log, sales_order, order_line, fact_sales.

Kế hoạch tiếp theo

Hạng mục	Nội dung	Trạng thái
B – Dashboard	6 màn hình Power BI/Metabase, BCG matrix, phân tích RFM	Đang thực hiện
C – Dự báo	Mô hình Prophet/SARIMA dự báo Q2/2026, tích hợp LLM	Chưa bắt đầu
D – Trình bày	Slide 10–15 trang, video demo 5–7 phút	Đang thực hiện

Với nền tảng dữ liệu đầy đủ từ 2025 đến T3/2026, nhóm tự tin có thể xây dựng dashboard phân tích và mô hình dự báo có giá trị kinh doanh thực tế cho Công ty Cổ phần Xe đạp Thống Nhất.

Báo cáo được tạo tự động bởi generate_report.py

Nhóm DataSync – DATA EXPLORERS 2026 – 03/05/2026