

BAO CAO KY THUAT

DATA EXPLORERS 2026 - Vong 2

From Data to Decision by MEXC Ventures

NHOM DATASYNC

Nguyen Dang Hoang An (Nhóm trưởng)

Le Thien Duc

Ta Ngoc Bao Ngan

Nguyen Trang Nhat Mai

Nguyen Quynh Tram

Học viên Chính sách và Phát triển

Email: datasync5ueh@gmail.com

Ngày hoàn thành: 03/05/2026

MỤC LỤC

1. Tổng quan dự án và bối cảnh
2. Hàng mục A: Xử lý đơn hàng tự động
 - 2.1 Kiến trúc pipeline
 - 2.2 Thu viện và công nghệ
 - 2.3 Xử lý file .eml (parse_email.py)
 - 2.4 Trích xuất PDF (parse_pdf.py)
 - 2.5 Kiểm tra hợp lệ (validate.py)
 - 2.6 Ghi database (db_writer.py)
 - 2.7 Điều phối pipeline (main.py)
 - 2.8 Xử lý trường hợp đặc biệt
3. Kết quả đạt được
4. Schema database
5. Hướng dẫn cài đặt và chạy
6. Kết luận và kế hoạch tiếp theo

1. TONG QUAN DU AN VA BOI CANH

Cong ty Co phan Xe dap Thong Nhat la doanh nghiep san xuat/phân phối xe đạp với quy mô hơn 200 SKU, 5 nhóm sản phẩm chính, vận hành theo mô hình B2B với hơn 700 đại lý trên cả nước. Hiện tại, đại lý đặt hàng qua email/diện thoại/Zalo, nhân viên nhập thủ công vào hệ thống ERP - quy trình tốn thời gian và dễ sai sót.

Mục tiêu Vòng 2 - DATA EXPLORERS 2026:

- Tự động hóa xử lý 1.132 đơn hàng email tháng 3/2026
- Xây dựng dashboard phân tích kinh doanh đa chiều (2025 - T3/2026)
- Dự báo nhu cầu Q2/2026 theo sản phẩm, màu sắc, hoạt động đại lý
- Trình bày và bảo vệ trước Hội đồng giám khảo


Phân bố điểm

Hang muc	Nội dung	Điểm tối đa
A	Vận hành: Xử lý đơn hàng tự động	25
B	Phân tích: Dashboard & Insights	30
C	Dự báo nhu cầu & Chiến lược	30
D	Trình bày & Bảo vệ	15
Tong		100

2. HANG MUC A: XU LY DON HANG TU DONG (25 DIEM)

Nhóm chọn Phương án A (Email + PDF .eml) để đạt mức tối đa 25/25 điểm. Pipeline được viết bằng Python, chạy hoàn toàn tự động không cần can thiệp thủ công sau khi khởi động.

2.1 Kiến trúc Pipeline



Pipeline thiết kế theo nguyên tắc idempotent: có thể chạy lại nhiều lần mà không gây trùng lặp dữ liệu. Có check: kiểm tra message_id (chỉ tiếp tục nếu chưa có trong email_log với status=SUCCESS) và so_number (kiểm tra trong sales_order trước khi insert).

2.2 Thu viện và Công nghệ

Thu viện	Phiên bản	Mục đích
Python	3.13	Ngon ngữ lập trình chính
pdfplumber	>=0.10.0	Trích xuất bảng biểu từ PDF
psycopg2-binary	>=2.9.0	Kết nối PostgreSQL
email (stdlib)	built-in	Phân tích cấu trúc MIME của .eml

2.3 Xử lý file .eml - parse_email.py

Mọi email có cấu trúc MIME phức tạp: header có thể mã hóa Base64 hoặc Quoted-Printable, file PDF đính kèm là payload nhị phân. Hàm parse_email() xử lý:

- Giải mã header: sử dụng decode_header() xử lý cả UTF-8 và ASCII
- Trích message_id, from_address, received_at (parsedate_to_datetime)
- Trích số đơn hàng từ Subject bằng regex: r"BH26[. _](\d+)"
- Tìm PDF đính kèm trong cây MIME (Content-Type: application/pdf)
- Giải mã base64 lấy pdf_bytes trả về
- Trích MST từ email body bằng regex: r"MST[:\s]*([0-9]{9,10})"

2.4 Trích xuất PDF - parse_pdf.py

Sử dụng pdfplumber để trích xuất bảng biểu từ PDF. Mọi đơn hàng có thể trải dài nhiều trang (3-5 trang với đơn hàng lớn). Cách xử lý:

- Trang đầu, bảng đầu = bảng header: số đơn, ngày, MST, tên đại lý
- Các bảng còn lại (mọi trang) = bảng sản phẩm: STT | Mã hàng | Tên SP | DVT | SL | Đơn giá | Thanh tiền
- Vị trí dòng tiêu đề (STT header row) và dòng tổng cộng (Tong cong row)
- Hàm _is_product_code() nhận diện mã hàng: số thuần 10-16 ký tự HOAC dạng TP0099.0000570
- Hàm _parse_amount() xử lý số VND: '1.898.148' -> 1898148.0 (cham là phân ngàn)

Kho khăn: PDF tạo từ phiên bản tiếng Việt nên tên sản phẩm bị garble unicode, tuy nhiên các trường dữ liệu quan trọng (mã hàng, số lượng, đơn giá) là ASCII nên không bị ảnh hưởng.

2.5 Kiểm tra hợp lệ - validate.py

Pipeline kiểm tra 5 nhóm điều kiện trước khi ghi database:

Nhóm kiểm tra	Nội dung	Xử lý khi lỗi
1. Số đơn hàng	Phải có so_number, không được trùng với DB	Fatal - bỏ qua đơn
2. Ngày đặt hàng	Phải thuộc tháng 3/2026	Ghi lỗi, bỏ qua
3. Khách hàng	Phải có MST trong PDF hoặc email body	Ghi lỗi
4. Mã sản phẩm	Phải tồn tại trong bảng product của DB	Ghi lỗi tổng hợp
5. Số lượng & giá	qty > 0, giá >= 0, thanh tiền khớp	Ghi lỗi từng dòng

Kiểm tra thanh tiền dùng dual-tolerance để xử lý cả đơn hàng số lượng lớn (>100 chiếc) và đơn giá lẻ thập phân:

```
expected = qty * unit_price
abs_diff = abs(expected - line_total)
rel_diff = abs_diff / line_total # relative tolerance
# Chỉ báo lỗi nếu CA HAI vượt ngưỡng:
if abs_diff > 50 and rel_diff > 0.0001: # 50 VND tuyệt đối VÀ 0.01% tương đối
    errors.append(...)
```

2.6 Ghi database - db_writer.py

Toàn bộ việc ghi dữ liệu trong 1 transaction để đảm bảo tính nhất quán:

- Lookup customer_code từ tax_code (MST): khớp chính xác, rồi khớp sau khi LTRIM('0')
- INSERT email_log: ghi trạng thái ngay từ đầu (PROCESSING)
- INSERT sales_order: số đơn, ngày, khách hàng, tổng tiền/sl (trigger từ dòng cập nhật)
- INSERT order_line (execute_batch): chèn nhanh toàn bộ dòng sản phẩm 1 lần
- UPDATE email_log: đổi status -> SUCCESS/ERROR
- populate_fact_sales(): INSERT...SELECT kết nối 7 bảng, NOT EXISTS để tránh trùng

2.7 Điều phối Pipeline - main.py

main.py kết nối các module lại, xử lý toàn bộ 1.132 file với progress bar, ghi log chi tiết và xuất summary.json sau khi chạy xong:

```
for eml_path in eml_files:
    eml = parse_eml(eml_path)          # B1: parse email
    pdf = parse_pdf(eml['pdf_bytes'])  # B2: parse PDF
    errs = validate_order(eml, pdf, valid_products, existing_so)
    if errs: log_error(); continue    # B3: validate
    customer = lookup_customer(conn, mst)
    insert_order(conn, eml, pdf, customer) # B4-5: ghi DB
    existing_so.add(so_number)         # cập nhật cache
```

2.8 Xử lý Trường hợp Đặc biệt

Trong quá trình chạy, phát hiện và xử lý các vấn đề phát sinh:

Van de	So luong	Giai phap
KH mới (MST chưa có trong DB)	92 MST	fix_missing_data.py: tự động thêm KH mới
Mã sản phẩm mới chưa có trong DB	~30 mã	fix_all_remaining.py: tự động thêm SP mới
Mã SP dạng TP0099.0000570 (có dấu chấm)	2 đơn	Cập nhật _is_product_code() regex
Sai lệch thanh tiền > 50 VND (đơn lớn)	1 đơn	Thêm relative tolerance 0.01%
Email trùng (đã xử lý ở lần chạy trước)	Nhiều	Skip qua message_id cache

3. KẾT QUẢ DỮ LIỆU

Sau khi chạy pipeline và xử lý các trường hợp đặc biệt:

Bảng	Số hàng	Mô tả
email_log	1.132 rows (100% SUCCESS)	Trạng thái xử lý từng email
sales_order	1.132 rows	Đơn hàng BH26.0935 -> BH26.2066
order_line	8.721 rows	Chi tiết sản phẩm từng đơn hàng
fact_sales (T3/2026)	8.721 rows	Dữ liệu phân tích doanh thu

Thống kê doanh thu tháng 3/2026:

Chỉ số	Giá trị
Tổng đơn hàng	1.132 đơn
Tổng số lượng	25.489 chiếc
Tổng doanh thu	~40,7 tỷ VND (40.691.947.133 VND)
Doanh thu bình quân/đơn	~35,9 triệu VND
Số dòng sản phẩm trung bình/đơn	7,7 dòng

100% đơn hàng tháng 3/2026 đã được xử lý thành công và ghi vào database, sẵn sàng cho các bước phân tích ở Hàng mục B và C.

4. SCHEMA DATABASE

Database: tnbike_db | Schema: tnbike | PostgreSQL 14

Gồm 9 bảng chính + 4 views + 1 trigger tự động cập nhật tổng tiền:

Bảng	Số hàng (sau pipeline)	Mô tả
product_group	5	Nhóm sản phẩm (Tree Em, Địa Hình,...)
product_line	~75	Dòng sản phẩm
product	247+	SKU sản phẩm (mã hàng, tên, đơn vị)
product_price	247+	Lịch sử giá bán
province	63	Tỉnh/thành phố + vùng miền
customer	700+	Đại lý (mã KH, tên, MST, tỉnh, tier)
sales_order	1.132 T3/2026	Đơn hàng (số, ngày, KH, tổng)
order_line	8.721 T3/2026	Dòng sản phẩm (mã, SL, giá, thành tiền)
fact_sales	8.721 T3/2026	Bảng phân tích (full dimension)
email_log	1.132	Nhật ký xử lý email (thêm bởi pipeline)

Trigger trg_order_line_after_insert: sau mỗi INSERT vào order_line, tự động cập nhật total_amount, total_quantity, line_count trong sales_order.

5. HƯỚNG DẪN CÀI ĐẶT VÀ CHẠY

Yêu cầu hệ thống

- Python 3.11+ (khuyến nghị 3.13)
- PostgreSQL 14+ (port 5432)
- RAM tối thiểu 4GB
- OS: Windows 10/11 hoặc Linux/macOS

Các bước cài đặt

B1: Clone repo

```
git clone https://github.com/NguyenAn1-data/dataexplorers2026-v2.git
cd dataexplorers2026-v2
```

B2: Cài thư viện

```
pip install -r pipeline/requirements.txt
```

B3: Cấu hình DB

```
copy pipeline\config.example.py pipeline\config.py
# Sửa config.py: điền mật khẩu PostgreSQL và đường dẫn thư mục email
```

B4: Khởi tạo DB

```
cd pipeline
python setup_db.py
# -> Tạo tnbike_db, chạy 01_create_tables.sql + 02_import_data.sql
```

B5: Chạy pipeline

```
python main.py
# -> Xử lý 1.132 file .eml, ghi vào database
# -> Xem kết quả: logs/summary.json
```

Kiểm tra kết quả

Sau khi chạy pipeline, kiểm tra trong pgAdmin hoặc psql:

```
-- Kiểm tra email_log
SELECT processing_status, COUNT(*) FROM tnbike.email_log GROUP BY 1;

-- Kiểm tra doanh thu T3/2026
SELECT COUNT(*), SUM(total_amount) FROM tnbike.sales_order
WHERE fiscal_year=2026 AND fiscal_month=3;

-- Kết quả mong đợi: 1132 SUCCESS, tổng ~40.7 tỷ VND
```

6. KẾT LUẬN VÀ KẾ HOẠCH TIẾP THEO

Kết quả Hàng mục A

Nhóm đã xây dựng thành công pipeline xử lý đơn hàng tự động đạt 100% hiệu quả (1.132/1.132 đơn hàng). Phương án A (Email + PDF) được chọn để tối đa hóa điểm số. Pipeline có khả năng:

- Xử lý cấu trúc MIME phức tạp của email (base64, quoted-printable, multi-part)
- Trích xuất chính xác dữ liệu từ PDF nhiều trang bằng pdfplumber
- Kiểm tra hợp lệ toàn diện với dual-tolerance cho tính toán tài chính
- Tự động đăng ký khách hàng và sản phẩm mới phát hiện trong email
- Chạy idempotent: an toàn khi restart, không gây dữ liệu trùng lặp
- Ghi dữ liệu theo đúng schema: email_log, sales_order, order_line, fact_sales

Kế hoạch tiếp theo

Hang muc	Noi dung	Trang thai
B - Dashboard	6 màn hình Power BI/Metabase, BCG matrix, RFM	Đang thực hiện
C - Dự báo	Prophet/SARIMA dự báo Q2/2026, LLM integration	Chưa bắt đầu
D - Báo cáo	Báo cáo kỹ thuật, Slide 10-15 trang, Video 5-7 phút	Đang thực hiện

Dữ liệu T3/2026 đã sẵn sàng trong database, cùng với lịch sử 2025-T2/2026, tạo nên nền tảng dữ liệu đầy đủ cho phân tích và dự báo ở các hạng mục tiếp theo.

Báo cáo này được tạo tự động bởi generate_report.py

Nhóm DataSync | DATA EXPLORERS 2026 | 03/05/2026